Base de datos de riesgo suicida y voz en adolescentes

FONDEF ID23I10376

TABLA DE CONTENIDO

1 Presentación general de la base de datos 2
2 Descripción de la base de datos 3
2.1 Resumen General 3
2.2 Base de datos tabular (Excel) 4
2.3 Repositorio de voz y habla 5
2.3.1 Estructura de carpetas por estudiante 6
2.3.2 Tipos de tareas de habla 6
2.3.3 Tipos de archivos 7
2.4 Caracterización de la población 8
2.4.1 Sexo de nacimiento 8
2.4.2 Edad de los participantes 8
2.4.3 Distribución del riesgo suicida según C-SSRS 8
2.4.4 Distribución de síntomas depresivos 9
2.4.5 Distribución de síntomas ansiosos 10
2.5 Relación entre Excel y audios 10
2.6 Uso de la base de datos 12

1 Presentación general de la base de datos

La base de datos desarrollada en el marco del proyecto FONDEF ID23I10376 está compuesta por registros de voz y habla, junto con información clínica y sociodemográfica asociada, recolectada en población adolescente en contexto educacional. Su objetivo principal es servir como insumo para el desarrollo, entrenamiento y validación de modelos de machine learning de detección y seguimiento de riesgo suicida basados en parámetros acústicos de la voz y del habla.

La población considerada corresponde a 527 estudiantes, mayoritariamente adolescentes de enseñanza media, provenientes de distintos establecimientos educacionales públicos de la ciudad de Temuco. La recolección de datos se realizó bajo protocolos estandarizados de coordinación, consentimiento informado y resguardo ético, asegurando la confidencialidad y anonimización de la información.

Para cada participante, la base de datos incluye múltiples tipos de señales de voz, adquiridas mediante tareas fonatorias estructuradas, que consideran: (i) lectura de un texto estandarizado, (ii) habla espontánea a partir de preguntas abiertas, y (iii) descripción de imágenes. Las grabaciones fueron realizadas utilizando equipamiento de audio de alta calidad, con condiciones controladas de adquisición y parámetros mínimos de frecuencia de muestreo y resolución adecuados para análisis acústico.

Adicionalmente, cada registro de voz se encuentra vinculado a información obtenida mediante instrumentos psicométricos validados, incluyendo la Escala de Severidad del Suicidio de Columbia (C-SSRS), el Inventario de Depresión de Beck (BDI), el PHQ-9 y la escala GAD-7, lo que permite caracterizar a los participantes en términos de riesgo suicida, síntomas depresivos y ansiedad. A partir de estos instrumentos se definieron etiquetas de clasificación que permiten distinguir entre usuarios con y sin riesgo, así como distintos niveles de severidad.

Como parte del proceso de curaduría de la base de datos, las señales de audio fueron sometidas a un preprocesamiento y etiquetado manual, identificando segmentos vocales relevantes, particularmente vocales, sobre las cuales se extraen los parámetros acústicos utilizados en los modelos de análisis. Este proceso se realizó utilizando herramientas especializadas y bajo criterios homogéneos de etiquetado.

En conjunto, la base de datos constituye un repositorio multimodal que integra señales de voz, anotaciones acústicas y variables clínicas y sociodemográficas, diseñado específicamente para apoyar el desarrollo y validación de sistemas automáticos de análisis de riesgo suicida en contextos educacionales reales

2 Descripción de la base de datos

La base de datos desarrollada en el marco del proyecto FONDEF ID23I10376 corresponde a un repositorio multimodal diseñado para apoyar el estudio de la relación entre características de la voz, el habla y variables asociadas al riesgo suicida en población adolescente. La base de datos integra información clínica, psicométrica y sociodemográfica junto con registros de voz y habla obtenidos mediante tareas estandarizadas de producción verbal.

Con el propósito de facilitar la gestión, análisis y trazabilidad de la información, la base de datos fue estructurada en dos componentes complementarios: una base de datos tabular que almacena la información clínica y psicométrica de los participantes, y un repositorio de voz y habla que contiene las grabaciones de audio, las anotaciones acústicas y las transcripciones textuales asociadas a cada participante. Ambos componentes se encuentran vinculados mediante un identificador anonimizado único, permitiendo relacionar la información clínica con los registros de voz y habla, manteniendo la confidencialidad de los participantes.

En las secciones siguientes se describe la estructura general de la base de datos, sus componentes principales, la organización del repositorio de voz y habla, y las características generales de la población incluida.

2.1 Resumen General

La base de datos final se compone de dos componentes complementarios, vinculados entre sí mediante un identificador anonimizado por participante:

- Base de datos tabular (Excel): contiene la información clínica, psicométrica y sociodemográfica de los participantes, así como las variables derivadas y etiquetas de clasificación utilizadas en los análisis.
- Repositorio de voz y habla: contiene las grabaciones de audio y los archivos derivados generados durante el proceso de preprocesamiento, limpieza y análisis de las señales.

La base de datos tabular contiene información correspondiente a 527 participantes, mientras que el repositorio de voz y habla dispone de registros asociados a 459 participantes. Las grabaciones fueron obtenidas mediante cuatro tareas estandarizadas de producción verbal y se encuentran organizadas mediante identificadores anonimizados que permiten vincular cada registro clínico con sus correspondientes archivos de voz.

La Tabla 1 presenta un resumen general de los principales componentes que conforman la base de datos.

La diferencia entre el número total de participantes registrados en la base de datos tabular y aquellos que disponen de registros de voz se debe a pérdidas ocurridas durante el proceso de adquisición y almacenamiento de las grabaciones. En consecuencia, los análisis clínicos y psicométricos pueden realizarse sobre la totalidad de los participantes disponibles, mientras que los análisis acústicos y multimodales se desarrollan sobre el subconjunto de participantes que cuentan con registros de voz válidos.

Tabla 1. Resumen general de la base de datos

Componente	Cantidad
Participantes en base de datos tabular	527
Participantes con registros de voz	459
Cobertura de registros de voz	87,1 %
Tareas de voz por participante	4
Tipos de archivos asociados	WAV, TextGrid y TXT
Instrumentos clínicos	C-SSRS, BDI, PHQ-9 y GAD-7

2.2 Base de datos tabular (Excel)

La base de datos tabular corresponde al repositorio central de información clínica, psicométrica y sociodemográfica de los participantes incluidos en el estudio. Esta base se encuentra almacenada en formato Microsoft Excel (.xlsx) y constituye el mecanismo de integración entre las distintas fuentes de información recolectadas durante el proyecto.

Cada registro de la base de datos corresponde a un participante individual identificado mediante un código anonimizado único almacenado en el campo "*cualestucodigo*", el cual permite vincular la información clínica con los registros de voz y habla contenidos en el repositorio de audio.

La versión consolidada de la base de datos contiene información correspondiente a 527 participantes y un total de 84 variables asociadas a antecedentes sociodemográficos, variables educacionales, antecedentes de conducta suicida y resultados de instrumentos psicométricos estandarizados.

Tabla 2. Resumen de la base de datos tabular

Característica	Valor
Participantes	527
Total de variables	84
Unidad de análisis	Estudiante
Identificación	Código anonimizado
Formato	Excel (.xlsx)

Las variables almacenadas incluyen tanto respuestas individuales a los instrumentos aplicados como puntajes agregados, categorías diagnósticas y variables derivadas utilizadas durante las etapas de análisis y modelamiento.

La información almacenada puede agruparse en seis categorías principales: identificación y variables sociodemográficas, antecedentes educacionales, antecedentes de conducta suicida, evaluación de riesgo suicida mediante la Escala de Severidad del Suicidio de Columbia (C-SSRS), evaluación de síntomas depresivos mediante el Inventario de Depresión de Beck (BDI) y el Patient Health Questionnaire (PHQ-9), y evaluación de síntomas ansiosos mediante la Escala de Ansiedad Generalizada (GAD-7).

Tabla 3. Principales categorías de variables incluidas en la base de datos tabular

Categoría	Descripción
Identificación	Código anonimizado del participante
Sociodemográficas	Sexo de nacimiento, identidad de género, orientación sexual, nacionalidad y composición del hogar
Educacionales	Variables asociadas al contexto académico y escolar
Conducta suicida	Antecedentes de ideación e intentos suicidas
C-SSRS	Respuestas individuales, puntaje total y clasificación de riesgo suicida
BDI	Respuestas individuales, puntaje total y categoría de síntomas depresivos
PHQ-9	Respuestas individuales, puntaje total y categoría de síntomas depresivos
GAD-7	Respuestas individuales, puntaje total y categoría de síntomas ansiosos
Variables derivadas	Etiquetas y variables de clasificación utilizadas en los análisis posteriores

2.3 Repositorio de voz y habla

El repositorio de voz y habla corresponde al componente acústico de la base de datos y contiene las grabaciones obtenidas durante las sesiones de adquisición realizadas a los participantes del estudio. Este repositorio está conformado por registros de voz asociados a 459 participantes, los cuales se encuentran vinculados a la base de datos tabular mediante un identificador anonimizado común.

Las grabaciones fueron obtenidas mediante tareas estandarizadas de producción verbal diseñadas para elicitar distintos tipos de discurso, incluyendo habla espontánea, lectura y descripción de imágenes. Además de los archivos de audio originales, el repositorio incorpora anotaciones acústicas y transcripciones textuales generadas durante el proceso de curaduría de los datos.

La organización del repositorio fue diseñada para facilitar la trazabilidad entre las distintas tareas realizadas por cada participante y los archivos derivados generados durante las etapas de procesamiento y análisis.

2.3.1 Estructura de carpetas por estudiante

Cada participante dispone de una carpeta individual identificada mediante el código anonimizado utilizado en la base de datos tabular. Dentro de esta carpeta se almacenan los registros asociados a las distintas tareas de voz y habla realizadas durante la sesión de evaluación.

La estructura general del repositorio se muestra a continuación:

```
/ID_ESTUDIANTE/
│
├── DESCRIPCION/
│   ├── ID_DESCRIPCION.WAV
│   ├── ID_DESCRIPCION.TextGrid
│   └── ID_DESCRIPCION.txt
│
├── PREGUNTA1/
│   ├── ID_PREGUNTA1.WAV
│   ├── ID_PREGUNTA1.TextGrid
│   └── ID_PREGUNTA1.txt
│
├── PREGUNTA2/
│   ├── ID_PREGUNTA2.WAV
│   ├── ID_PREGUNTA2.TextGrid
│   └── ID_PREGUNTA2.txt
│
└── TEXTO_EL_ABUELO/
    ├── ID_TEXTO_EL_ABUELO.WAV
    └── ID_TEXTO_EL_ABUELO.TextGrid
```

Cada subcarpeta contiene la grabación de audio correspondiente a la tarea realizada, junto con las anotaciones temporales generadas en Praat (.TextGrid) y, cuando corresponde, la transcripción textual del discurso producido por el participante (.txt). La tarea de lectura del texto "El Abuelo" no requiere archivo de transcripción debido a que el contenido leído corresponde a un texto previamente conocido y estandarizado.

2.3.2 Tipos de tareas de habla

Las grabaciones almacenadas en el repositorio corresponden a cuatro tareas diseñadas para capturar distintos tipos de producción verbal.

La combinación de estas tareas permite disponer de muestras de habla espontánea y habla controlada, facilitando la extracción y análisis de características acústicas y lingüísticas bajo diferentes condiciones de producción verbal.

Tabla 4. Tareas de voz y habla incluidas en la base de datos

Carpeta	Tipo de tarea	Descripción
PREGUNTA1	Habla espontánea	Respuesta a la pregunta "¿Qué es lo mejor que te ha pasado?"
PREGUNTA2	Habla espontánea	Respuesta a la pregunta "¿Qué es lo peor que te ha pasado?"
TEXTO_EL_ABUELO	Lectura	Lectura en voz alta del texto estandarizado "El Abuelo"
DESCRIPCION	Descripción de imagen	Descripción libre de una lámina visual

Nota: Todas las grabaciones se almacenan en formato WAV, con parámetros adecuados para análisis acústico (frecuencia de muestreo ≥16 kHz, resolución de 16 bits).

2.3.3 Tipos de archivos

Para cada tarea se dispone de distintos tipos de archivos generados durante el proceso de adquisición y preprocesamiento de datos.

Tabla 5. Tipos de archivos contenidos en el repositorio de voz

Tipo de archivo	Descripción
WAV	Grabación original de audio correspondiente a cada tarea de voz y habla
TextGrid	Archivo de anotaciones temporales generado mediante Praat para el etiquetado manual de segmentos de interés dentro de la señal
TXT	Transcripción textual del contenido verbal producido por el participante

Los archivos WAV corresponden a las grabaciones originales utilizadas para el análisis acústico. Los archivos TextGrid almacenan las anotaciones realizadas durante el proceso de segmentación y etiquetado de las señales, permitiendo identificar regiones específicas de interés para la extracción de parámetros acústicos. Finalmente, los archivos TXT contienen las transcripciones textuales asociadas a las tareas de habla espontánea y descripción de imágenes, proporcionando una representación textual del discurso producido por cada participante.

2.4 Caracterización de la población

La base de datos tabular contiene información correspondiente a 527 participantes. Con el propósito de describir la composición de la muestra incluida en el repositorio, a continuación, se presentan algunas características generales de la población considerando variables sociodemográficas y las principales escalas psicométricas utilizadas durante el proceso de evaluación.

2.4.1 Sexo de nacimiento

La Tabla 6 presenta la distribución de los participantes según el sexo de nacimiento reportado al momento de la evaluación.

Tabla 6. Distribución de participantes según sexo de nacimiento

Sexo de nacimiento	Frecuencia	Porcentaje (%)
Mujeres	286	54,3
Hombres	240	45,5
Intersexual	1	0,2
Total	**527**	**100,0**

2.4.2 Edad de los participantes

La Tabla 7 presenta la distribución de los participantes según la edad registrada en la base de datos tabular.

Tabla 7. Distribución de participantes según edad

Edad	Frecuencia	Porcentaje (%)
14	42	8,0
15	112	21,3
16	150	28,5
17	107	20,3
18	31	5,9
19	10	1,9
Sin dato	75	14,2
Total	**527**	**100,0**

2.4.3 Distribución del riesgo suicida según C-SSRS

La base de datos incluye los puntajes obtenidos mediante la Escala de Severidad del Suicidio de Columbia (C-SSRS). La Tabla 8 presenta la distribución de participantes según el puntaje total obtenido en esta escala.

Tabla 8. Distribución de participantes según puntaje total C-SSRS

Puntaje total	Frecuencia
0	191
1	97
2	65
3	57
4	50
5	37
6	30
Total	**527**

2.4.4 Distribución de síntomas depresivos

La base de datos incorpora dos instrumentos para la evaluación de síntomas depresivos: el Inventario de Depresión de Beck (BDI) y el Patient Health Questionnaire (PHQ-9).

Tabla 9. Distribución de participantes según categorías del BDI

Categoría	Frecuencia
Depresión mínima	133
Depresión leve	87
Depresión moderada	168
Depresión severa	139
Total	**527**

Tabla 10. Distribución de participantes según categorías del PHQ-9

Categoría	Frecuencia
Sin depresión	194
Depresión leve	133
Depresión moderada	87
Depresión moderadamente severa	55
Depresión severa	58
Total	**527**

2.4.5 Distribución de síntomas ansiosos

La evaluación de síntomas ansiosos se realizó mediante la escala GAD-7.

Tabla 11. Distribución de participantes según categorías del GAD-7

Categoría	Frecuencia
Ansiedad mínima	246
Ansiedad leve	151
Ansiedad moderada	95
Ansiedad severa	35
Total	**527**

2.5 Relación entre Excel y audios

La integración entre la base de datos tabular y el repositorio de voz y habla se realiza mediante un identificador anonimizado único almacenado en el campo *cualestucodigo*. Este identificador corresponde al código asignado a cada participante y es utilizado tanto en la base de datos tabular como en la estructura de carpetas del repositorio de audio, permitiendo vincular la información clínica, psicométrica y sociodemográfica con las grabaciones de voz asociadas.

La base de datos tabular contiene información correspondiente a 527 participantes, mientras que el repositorio de voz y habla dispone de registros asociados a 459 participantes. Esta diferencia se debe a pérdidas ocurridas durante el proceso de adquisición y almacenamiento de las grabaciones, incluyendo registros incompletos, archivos dañados o audios que no pudieron ser recuperados durante las etapas de consolidación de la base de datos.

La existencia de un identificador común permite mantener la trazabilidad entre ambos componentes y facilita la realización de análisis multimodales que integran información clínica y psicométrica con características acústicas y lingüísticas extraídas de las señales de voz.

Tabla 12. Correspondencia entre los componentes de la base de datos

Componente	Participantes	Información contenida	Formato
Base de datos tabular	527	Variables clínicas, psicométricas, sociodemográficas y etiquetas de clasificación	.xlsx
Repositorio de voz y habla	459	Grabaciones de voz, anotaciones acústicas y transcripciones	WAV, TextGrid y TXT
Vinculación	459	Participantes con información clínica y registros de voz asociados mediante el identificador *cualestucodigo*	-

Con el fin de resguardar la confidencialidad de los participantes, toda la información almacenada en la base de datos fue anonimizada mediante la asignación de un identificador único (*cualestucodigo*), eliminando cualquier dato que permitiera la identificación directa de los estudiantes. Este identificador es utilizado de manera consistente tanto en la base de datos tabular como en el repositorio de voz y habla, permitiendo mantener la trazabilidad entre las distintas fuentes de información sin comprometer la privacidad de los participantes. Asimismo, el acceso a la base de datos se encuentra restringido al equipo de investigación autorizado, de acuerdo con los protocolos éticos y de protección de datos establecidos para el proyecto.

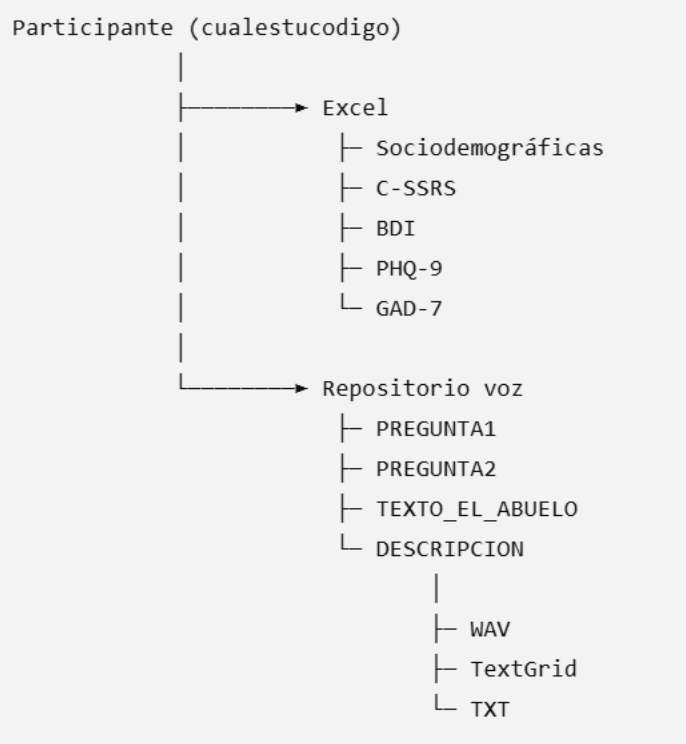


Figura 1. Relación entre los componentes de la base de datos.

La Figura 1 presenta la arquitectura general de la base de datos. La información de cada participante se organiza mediante un identificador anonimizado único que permite vincular los registros almacenados en la base de datos tabular con el repositorio de voz y habla. Mientras la base de datos tabular concentra las variables clínicas, psicométricas y sociodemográficas, el repositorio de voz almacena las grabaciones correspondientes a las tareas PREGUNTA1, PREGUNTA2, TEXTO_EL_ABUELO y DESCRIPCION. Para cada tarea se dispone de archivos de audio en formato WAV y de archivos derivados, tales como anotaciones acústicas en formato TextGrid y transcripciones textuales en formato TXT. Esta organización permite mantener la trazabilidad de los datos y facilita la integración de información proveniente de distintas modalidades de análisis.

2.6 Uso de la base de datos

La base de datos fue desarrollada con el propósito de apoyar la investigación y el desarrollo de herramientas computacionales orientadas a la detección y evaluación del riesgo suicida en población adolescente mediante el análisis de señales de voz y habla.

La integración de información clínica, psicométrica, sociodemográfica y acústica permite abordar el estudio del riesgo suicida desde una perspectiva multimodal, facilitando el desarrollo y validación de modelos de aprendizaje automático basados en distintas fuentes de información.

En particular, la base de datos permite realizar:

- Análisis descriptivos y estadísticos de variables clínicas, psicométricas y sociodemográficas.
- Estudios de asociación entre variables clínicas y características de la voz y el habla.
- Extracción y análisis de parámetros acústicos a partir de las grabaciones de voz.
- Análisis lingüísticos y semánticos utilizando las transcripciones textuales asociadas a las tareas de habla.
- Desarrollo, entrenamiento y validación de modelos de aprendizaje automático para la detección y clasificación del riesgo suicida.
- Evaluación de estrategias multimodales que integran información clínica, acústica y lingüística.

La estructura modular de la base de datos permite además incorporar nuevas variables, registros de voz o anotaciones en futuras etapas del proyecto, facilitando su utilización en investigaciones posteriores relacionadas con salud mental, procesamiento de voz y análisis computacional del lenguaje.

En conjunto, la base de datos constituye un repositorio multimodal único que integra información clínica, psicométrica, sociodemográfica y registros de voz y habla en población adolescente, proporcionando una plataforma robusta para el desarrollo y evaluación de herramientas automáticas de apoyo a la detección y seguimiento del riesgo suicida.